

25. Общая схема оценки параметров линейной множественной регрессии методом наименьших квадратов.

3.3.1. Линейная модель множественной регрессии

Линейная модель множественной регрессии имеет вид

$$Y = \beta_0 + \sum_{i=1}^p \beta_i X_i + \varepsilon,$$

где Y - объясняемая переменная; X_i - объясняющие переменные; β_i - параметры модели; ε - ошибка модели (случайные отклонения); n - число наблюдений, p - число факторов.

Исходными данными для оценки параметров $\beta_0, \beta_1, \dots, \beta_p$ являются наблюдаемые значения зависимой переменной Y (вектор-столбец $[n \times 1]$) и независимые переменные, объединенные в матрицу X (ее размерность $[n \times (p + 1)]$):

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_{41} & x_{42} & \dots & x_{4p} \end{pmatrix},$$

где n - число объектов (наблюдений); p - число факторов. Столбец из единиц введен для отражения в модели свободного члена уравнения регрессии β_0 . Если ввести обозначения для вектора-столбца параметров β и вектора случайных ошибок ε :

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix},$$

то модель множественной регрессии можно записать в матричном виде:

$$Y = X\beta + \varepsilon$$

Оценкой модели по выборке является уравнение:

$$\hat{Y} = Xb + e,$$

где вместо неизвестных коэффициентов β и ошибок ε используются их оценки - вектор b и фактическая ошибка - вектор e .

Метод наименьших квадратов (МНК).

Теорема Гаусса-Маркова. Предположим, что:

1. $Y = X\beta + \varepsilon$;
2. X - детерминированная $[n \times (p + 1)]$ матрица, имеющая максимальный ранг $p + 1$;
3. $M(\varepsilon) = 0$; $D(\varepsilon) = \sigma^2 I_n$.

Тогда оценка метода наименьших квадратов $b = (X^T X)^{-1} X^T Y$ является наиболее эффективной (в смысле наименьшей дисперсии) оценкой в классе линейных (по Y) несмещенных оценок.

Целью МНК является выбор вектора оценок b , минимизирующего сумму квадратов остатков e_i . Обозначим $\hat{Y} = Xb + e$ - построенную нами модель (здесь b_i - оценки коэффициентов β_i , e - ошибка модели). Тогда в математической форме исходное положение МНК будет выглядеть одним

из нижеуказанных способов:

$$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \longrightarrow \min$$

$$\sum_{i=1}^n (Y_i - b_0 - b_1 X_{i1} - b_2 X_{i2} - \dots - b_p X_{ip})^2 \longrightarrow \min$$

$$\sum_{i=1}^n e_i^2 \longrightarrow \min$$

Рассмотрим более подробно условия применимости МНК.

1. Матрица X - детерминированная - матрица, состоящая из констант (в отличие от стохастической матрицы X , которая содержит случайные величины);

2. Математическое ожидание значений ошибки модели для всех наблюдений равно нулю

$$M(\varepsilon_i) = 0, \quad M(\varepsilon) = \bar{0}$$

3. Значение дисперсии ошибки является постоянной величиной для всех наблюдений $i = 1, \dots, n$ (ошибки *гомоскедастичны*)

$$D(\varepsilon_i) = \sigma_\varepsilon^2 I = \text{const.}$$

4. Значения ошибки, для различных наблюдений независимы между собой, т.е. ковариация ошибок $\varepsilon_i, \varepsilon_j (i \neq j)$ равна нулю (отсутствие *автокорреляции*)

$$\text{cov}(\varepsilon_i, \varepsilon_j) = 0.$$

5. Значения независимых факторов модели и ошибки, рассматриваемые для одного и того же наблюдения, являются независимыми, т.е. их ковариация равна нулю

$$\text{cov}(X_{ij}, \varepsilon_j) = 0 \text{ для } i = 1, \dots, n.$$

6. Матрица $(X^T X)$ является невырожденной. Это означает, что факторы $X_{ij}, i = 1, \dots, n$ независимы между собой (их выборочные парные коэффициенты корреляции не превосходят некоторого порога r^*)

$$|r_{ij}| \leq r^*.$$

7. Случайные ошибки распределены по стандартному нормальному закону. Это последнее условие уже не связано с применимостью МНК, однако оно необходимо, поскольку позволяет получить статистические оценки значимости регрессионного уравнения и регрессионных коэффициентов.

Свойства 2 и 5 для ФАКТИЧЕСКОЙ ошибки e выполняются априори при использовании МНК. В то время, как другие свойства (3, 4) должны проверяться для модели после ее построения. Нарушения условия (6) приводит к *мультиколлинеарности* (см. ниже).

Статистические свойства МНК-оценок.

1. Несмещенная оценка дисперсии ошибок модели σ_ε^2 определяется:

$$S_\varepsilon^2 = \frac{e^T e}{n - p - 1} = \frac{\sum e_i^2}{n - p - 1}$$

2. Дисперсия $S_{b_i}^2$ коэффициента регрессии b_i равна i -ому диагональному элементу матрицы ковариаций для коэффициентов:

$$\text{cov}(b_i, b_j) = \sigma_\varepsilon^2 (X^T X)^{-1}$$

3. При выполнении предпосылок МНК оценки коэффициентов регрессии являются несмещенными (математическое ожидание оценки равно оцениваемому параметру $M(b_i) = \beta_i$), эффективными (дисперсия b_i минимальна) и состоятельными (при $n \rightarrow \infty$ она стремится по вероятности к оцениваемому параметру):

$$\lim_{n \rightarrow \infty} P(|b_i - \beta_i| < \varepsilon) = 1.$$

Иначе говоря, состоятельной называется такая оценка, которая дает точное значение для большой выборки независимо от входящих в нее конкретных наблюдений.