

# 29. Основные числовые характеристики и свойства оптимальности главных компонент в методе главных компонент.

## 1. Свойства оптимальности главных компонент

Метод главных компонент основан на переходе к новой системе координат с целью «сжатия» информации. Критерием качества (информативности) служит максимизация дисперсии новых переменных.

**Функционал информативности:**

$$I_{p'}[F(Z)] = \frac{D(F_1) + \dots + D(F_{p'})}{D(Z_1) + \dots + D(Z_p)} \longrightarrow \max$$

## Определение и вывод первой главной компоненты

**Определение:** Первой главной компонентой  $f_1(Z)$  называется такая нормированно-центрированная линейная комбинация исходных показателей  $Z$ , которая обладает **наибольшей дисперсией**.

Линейная комбинация имеет вид  $f_1 = ZU_1$ , где  $U_1$  — вектор коэффициентов.

**Доказательство (Вывод через задачу оптимизации):**

Требуется найти вектор  $U_1$ , максимизирующий дисперсию при условии нормировки:

$$\begin{cases} D(ZU_1) \longrightarrow \max \\ U_1^T U_1 = 1 \end{cases}$$

1. Выразим дисперсию:

$$D(ZU_1) = M[(ZU_1)^2] = M[U_1^T Z^T Z U_1] = U_1^T M(Z^T Z) U_1 = U_1^T R_x U_1$$

(где  $R_x$  — корреляционная матрица стандартизованных данных).

Задача принимает вид:

$$\begin{cases} U_1^T R_x U_1 \longrightarrow \max \\ U_1^T U_1 = 1 \end{cases}$$

## 2. Функция Лагранжа:

Составим функцию для поиска условного экстремума:

$$\varphi(U_1, \lambda) = U_1^T R_x U_1 - \lambda(U_1^T U_1 - 1)$$

## 3. Необходимое условие экстремума:

Найдем производную по вектору  $U_1$  и приравняем её к нулю:

$$\frac{\partial \varphi}{\partial U_1} = 2R_x U_1 - 2\lambda U_1 = 0$$

Сократив на 2, получаем систему линейных однородных уравнений:

$$R_x U_1 - \lambda U_1 = 0 \quad \text{или} \quad (R_x - \lambda I)U_1 = 0$$

## 4. Решение системы:

Чтобы система имела ненулевое решение, определитель матрицы должен быть равен нулю:

$$|R_x - \lambda I| = 0$$

Это характеристическое уравнение. Следовательно,  $\lambda$  — это собственное число матрицы  $R_x$ , а  $U_1$  — соответствующий собственный вектор.

## 5. Максимизация дисперсии:

Докажем, чему равна дисперсия полученной компоненты. Умножим уравнение  $R_x U_1 = \lambda U_1$  слева на  $U_1^T$ :

$$U_1^T R_x U_1 = U_1^T \lambda U_1 = \lambda(U_1^T U_1)$$

Так как  $U_1^T U_1 = 1$ , получаем:

$$D(f_1) = U_1^T R_x U_1 = \lambda$$

Чтобы дисперсия была **максимальной**, необходимо выбрать **наибольшее** собственное число  $\lambda_1$ .

**Вывод:** Первая главная компонента соответствует наибольшему собственному числу  $\lambda_1$ , а вектор коэффициентов  $U_1$  — это собственный вектор, соответствующий  $\lambda_1$ .

## k-я главная компонента

Аналогично определяется  $k$ -я главная компонента ( $f_k = ZU_k$ ), которая должна иметь максимальную дисперсию и **не коррелировать** с предыдущими.

Решение этой задачи приводит к тому, что  $U_k$  — это собственный вектор, соответствующий  $k$ -му по величине собственному числу  $\lambda_k$ . Дисперсия этой компоненты равна  $D(f_k) = \lambda_k$ .

## 2. Основные числовые характеристики главных компонент

Определим характеристики вектора главных компонент  $F = ZU$ , где  $U$  — матрица собственных векторов.

### 1) Математическое ожидание

$$M(F) = M(ZU) = U \cdot M(Z) = 0$$

(так как исходные данные  $Z$  центрированы,  $M(Z) = 0$ ).

### 2) Ковариационная матрица (Доказательство некоррелированности)

Ковариационная матрица  $S_F$  главных компонент является диагональной.

**Доказательство:**

$$S_F = M(F^T F) = M[(ZU)^T (ZU)] = M[U^T Z^T Z U] = U^T M[Z^T Z] U = U^T R_x U$$

Известно, что собственные векторы и числа связаны соотношением (из уравнения (10) лекции):

$$R_x U_k = \lambda_k U_k$$

Домножим это равенство слева на вектор  $U_j^T$ :

$$U_j^T R_x U_k = U_j^T \lambda_k U_k = \lambda_k (U_j^T U_k)$$

Собственные векторы матрицы  $R_x$  обладают свойствами ортогональности и нормированности:

- При  $j \neq k$  (ортогональность):  $U_j^T U_k = 0$ .
- При  $j = k$  (нормировка):  $U_k^T U_k = 1$ .

Следовательно:

$$U_j^T R_x U_k = \begin{cases} 0, & j \neq k \\ \lambda_k, & j = k \end{cases}$$

Таким образом, матрица  $S_F$  имеет вид:

$$S_F = U^T R_x U = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_p \end{pmatrix}$$

Это доказывает, что главные компоненты не коррелированы (внедиагональные элементы равны нулю).

### 3) Сумма дисперсий

Сумма дисперсий всех главных компонент равна сумме дисперсий исходных признаков (равной  $p$  для стандартизованных данных).

#### Доказательство:

Сумма дисперсий есть след (trace) матрицы  $S_F$ :

$$\sum_{k=1}^p D(f_k) = \text{tr}(S_F) = \text{tr}(U^T (R_x U))$$

Используем свойство следа матрицы  $\text{tr}(AB) = \text{tr}(BA)$ . Переставим  $U^T$  в конец:

$$\text{tr}((R_x U) U^T) = \text{tr}(R_x (U U^T))$$

Так как матрица собственных векторов  $U$  ортогональна, то  $U U^T = I$  (единичная матрица):

$$= \text{tr}(R_x I) = \text{tr}(R_x) = \sum_{k=1}^p 1 = p$$

(так как на диагонали корреляционной матрицы  $R_x$  стоят единицы).