

37. Дискриминантный анализ. Классификация с использованием вероятностно-статистических методов (расстояние Махаланобиса и апостериорная вероятность). Простые классифицирующие функции и их применение для классификации.

Дискриминантный анализ — это раздел многомерного статистического анализа, предназначенный для решения задач классификации объектов в ситуациях, когда **группы (классы) известны заранее**. В отличие от кластерного анализа, этот метод относится к обучению «с учителем», так как строится на основе обучающей выборки, где принадлежность каждого объекта к определенной группе уже определена.

Расстояние Махаланобиса

Расстояние Махаланобиса представляет собой меру близости конкретного объекта к центроиду (средней точке) каждой из известных групп в многомерном пространстве признаков.

В тех случаях, когда переменные коррелированы, измерены в разных единицах и имеют разные стандартные отклонения, бывает трудно определить понятие «расстояние». В 1963г. Махаланобис предложил использовать обобщенную меру расстояния, которая устраняет эти трудности:

$$d^2(X/G_k) = (x - \mu_k)^T S_*^{-1} (x - \mu_k) \quad (23)$$

Здесь $d^2(X/G_k)$ — квадрат расстояния от объекта X (данный объект) до центра класса k ; μ_k — вектор средних значений переменных для класса k ; S_* — обобщенная ковариационная матрица внутригрупповых ковариаций.

После вычисления d^2 для каждого объекта, его относят в класс с наименьшим значением d^2 . Это класс, чей типичный профиль по дискриминантным переменным больше похож на профиль для этого объекта.

- **Особенности метрики:** В отличие от обычного евклидова расстояния, расстояние Махаланобиса **учитывает корреляционные связи** между переменными и их разную изменчивость (дисперсии). Это делает его более точным инструментом для анализа сложных статистических данных, где признаки взаимосвязаны.
- **Правило классификации:** Объект относится к той группе, **расстояние Махаланобиса до центра которой минимально**.
- **Практическая реализация:** В статистических программах (например, Statistica) результаты часто представляются в виде матрицы квадратов расстояний Махаланобиса от объектов до центров всех выделенных групп.

Апостериорная вероятность

Апостериорная вероятность — это вероятность того, что объект принадлежит к определенному классу, вычисленная **после (post)** получения и анализа значений его признаков.

Обозначим $P(X/G_k)$ вероятность того, что объект X действительно принадлежит классу k . Оценить эту величину можно как долю объектов в классе G_k , которые отстоят от центра дальше, чем наш объект:

$$P(X/G_k) = \frac{\widetilde{m}_k}{n_k} \quad (24)$$

где \widetilde{m}_k — число объектов в классе k , расположенных от центра «дальше», чем X ; n_k — число объектов в классе k , причем $n_k = m_k + \widetilde{m}_k$, а m_k — число объектов в классе k , расположенных к центру «ближе», чем X .

Для объекта X сумма данных вероятностей не равна 1, так как классы могут перекрываться.

Апостериорная вероятность того, что объект X является членом класса k рассчитывается по формуле:

$$P_{\text{ап}}(G_k/X) = \frac{P(X/G_k) \cdot P(G_k)}{\sum_{k=1}^g P(X/G_k) \cdot P(G_k)} \quad (25)$$

где $P(G_k)$ — априорная вероятность принадлежности объектов к классу G_k ; $P(X/G_k)$ — условная вероятность того, что объект X является членом класса k (доля объектов в классе G_k , отстоящих от центра «дальше», чем X).

- **Использование априорных данных:** Для вычисления апостериорных значений необходимо задать априорные вероятности (предположения о частоте классов до начала исследования). Они могут быть:
 1. **Равными** для всех групп.
 2. **Пропорциональными** фактическим размерам групп в обучающей выборке.
- **Правило классификации:** Модель классифицирует объект в ту группу, для которой апостериорная вероятность является максимальной.
- **Значимость:** Данный подход позволяет не просто распределить объекты, но и оценить степень уверенности в правильности классификации для каждого конкретного случая.

1.5.3. Простые классифицирующие функции

Фишер (1936) был первым, кто предположил, что классификация должна проводиться с помощью линейной комбинации дискриминантных переменных. Он предложил применять линейную комбинацию, которая максимизирует различия между классами, но минимизирует дисперсию внутри классов. Таким образом, для каждого класса определяется своя линейная комбинация, которая и называется простой классифицирующей функцией. Она имеет следующий вид:

$$h_k = b_{k0} + b_{k1}X_1 + b_{k2}X_2 + \dots + b_{kp}X_p \quad (26)$$

где h_k – значение простой классифицирующей функции для класса k , а b_{ki} – коэффициенты, которые необходимо определить. Объект относится к классу, для которого значение h максимально. Коэффициенты классифицирующих функций определяются по формулам:

$$b_{ki} = (n - g) \sum_{j=1}^p u_{ij} X_{jk}, \quad (27)$$

где u_{ij} – элемент матрицы, обратной к внутригрупповой матрице W сумм попарных произведений. Постоянный член определяется с помощью выражения

$$b_{k0} = -0,5 \sum_{j=1}^p b_{kj} X_{jk}. \quad (28)$$

Коэффициенты простых классифицирующих функций обычно не интерпретируются, так как они не стандартизованы и каждому классу соответствует своя функция. Точные значения функции роли не играют: необходимо знать лишь, для какого класса это значение наибольшее. Именно к нему объект ближе всего.

Суть классифицирующих функций

Классифицирующие функции представляют собой линейные комбинации независимых переменных (признаков), которые позволяют вычислить «показатель близости» объекта к каждой из групп. Для каждого класса j строится свое отдельное уравнение.

Основная формула функции для группы j :

$$S_j = c_j + w_{1j}x_1 + w_{2j}x_2 + \dots + w_{pj}x_p$$

Где:

- S_j — результирующее значение (классификационный показатель) для группы j ;
- c_j — константа для j -й группы;
- w_{1j}, \dots, w_{pj} — весовые коэффициенты признаков, рассчитанные для данной группы;
- x_1, \dots, x_p — фактические значения признаков классифицируемого объекта.

Применение для классификации

Процесс классификации с использованием этих функций выглядит следующим образом:

1. **Расчет показателей:** Значения признаков нового объекта (x_i) подставляются в уравнения функций для **каждой** из имеющихся групп.

2. **Сравнение результатов:** Для каждого объекта получается набор значений S_1, S_2, \dots, S_k .

3. **Принятие решения:** Объект относится к той группе, для которой значение классифицирующей функции оказалось **максимальным**.

Математически это означает, что объект имеет наибольшую вероятность принадлежности именно к этой группе.

Особенности и условия применения

- **Оценка качества:** Эффективность разделения групп этими функциями проверяется с помощью статистики **Лямбда Уилкса (Λ)**. Значения Λ , близкие к 0, указывают на четкое различие между группами, а близкие к 1 — на плохую дискриминацию.
- **Допущения:** Метод предполагает, что независимые переменные имеют многомерное нормальное распределение, а ковариационные матрицы групп примерно равны.
- **Практическое использование:** В программных пакетах (например, Statistica) расчет коэффициентов w_{ij} и констант c_j происходит автоматически на основе обучающей выборки.